Master SEP — Data Mining

Livré ou Remboursé

Rapport sur le modèle actuel de prédiction des retards de livraison

---

Modèle évalué	forêt aléatoire `foret_100` (300 arbres)
Données	Olist, e-commerce brésilien (Kaggle, CC BY-NC-SA 4.0)
Entraînement	commandes de janvier à décembre 2017 (43 956)
Test	commandes du 1er janvier au 29 août 2018 (53 344)
Objet	état des lieux avant le travail d'amélioration

31 octobre 2026

Synthèse

En une phrase

Le modèle actuel est **utile pour l'assureur** (il double le bénéfice par rapport à la situation sans modèle) mais **faible statistiquement** (ROC-AUC de 0,641) et **sous-estime le risque en 2018**, ce qui laisse une marge d'amélioration nette.

Indicateur (test 2018)	Valeur	Lecture
Bénéfice de l'assureur	11 049 R$	$\times 2{,}1$ par rapport à « proposer à tous » (5 191 R$)
Ratio sinistres / primes	0,68	68 R$ de sinistres pour 100 R$ de primes
Part des commandes à qui on propose	81,8 %	18,2 % de refus
ROC-AUC	0,641	0,5 = hasard ; capacité de tri modeste
PR-AUC	0,144	hasard = 0,087 (taux de sinistre)
Score de Brier	0,0783	référence sans modèle : 0,0795
Probabilité moyenne prédite	7,0 %	taux réel : 8,7 % (sous-estimation)

Ce qui fonctionne. La démarche est rigoureuse : split temporel, test regardé une seule fois, choix du modèle sur une métrique métier, contrôle par refus au hasard, contrainte d'équité respectée dans les cinq régions.

Ce qui limite le modèle. Une capacité de tri modeste, des probabilités trop basses dans les tranches risquées, deux variables qui dégradent le classement, et une forte dérive du taux de retard entre 2017 et 2018.

Premiers essais (section 7). Retirer les deux variables est neutre et la calibration dégrade le résultat : le défaut de calibration vient de la dérive temporelle. La régression logistique trie mieux que la forêt.

Nouveau modèle (section 8). Une régression logistique avec trois variables « trajet » (historique des livraisons entre l'État du vendeur et celui du client) porte la ROC-AUC du test 2018 de 0,641 à **0,673** et le bénéfice de 11 049 à **12 238 R$** (+11 %). Le plafond de 20 % par région est respecté, mais les refus se concentrent davantage sur certains États (58 % à Rio de Janeiro).

Choix d'équité (section 9). L'équipe a retenu un **plafond de 20 % de refus par État**. Tous les États sont désormais à 20 % de refus au plus ; le bénéfice sur le test 2018 est de **9 417 R$** ($\times 1{,}8$ par rapport à « proposer à tous »), soit 2 821 R$ de moins qu'avec un plafond par région.

Modèle initial et modèle final

En une phrase

Le modèle final **prédit mieux** et **traite tous les États de la même façon**, mais il rapporte 1 632 **R$ de moins** sur le test 2018 que le modèle initial : ce coût vient du choix d'équité par État, pas d'une moins bonne qualité de prédiction.

Ce qui a changé

	Modèle initial	Modèle final
Algorithme	Forêt aléatoire (300 arbres)	Régression logistique
Variables	11	12 : 9 de base + 3 « trajet »
Choix du modèle	Bénéfice, 1 fenêtre de validation	ROC-AUC moyenne, 2 fenêtres
Règle d'équité	20 % de refus au plus par région	20 % de refus au plus par État
Tests automatiques	18	23, dont 4 contre les fuites

Qualité des prédictions

Ces mesures ne dépendent pas de la règle d'équité.

	Initial	Final
ROC-AUC, validation 2017 (moyenne des 2 fenêtres)	0,590	**0,644**
ROC-AUC, test 2018	0,641	**0,673**
PR-AUC, test 2018 (hasard : 0,087)	0,144	**0,150**
Score de Brier	0,0783	**0,0776**
Probabilité moyenne prédite (réel : 8,7 %)	7,0 %	**9,0 %**
Taux de retard des 10 % les plus risqués	17,6 %	17,6 %

Résultats sur le test 2018, chacun avec sa règle

	Initial (par région)	Final (par État)
Bénéfice	**11 049 R$**	9 417 R$
Ratio sinistres / primes	**0,68**	0,74
Garantie proposée à	81,8 %	**83,9 %**
Refus par État (États d'au moins 200 commandes)	9 à 39 %	**11 à 20 %**
Taux de retard des commandes refusées / acceptées	11,0 / 8,2 %	9,9 / 8,5 %

À règle égale

Pour séparer l'effet du modèle de celui de la règle, chaque modèle est évalué avec les deux règles (bénéfice sur le test 2018) :

	Initial	Final	Écart
Plafond de 20 % par région	11 049 R$	**12 238 R$**	+1 189 R$
Plafond de 20 % par État	**10 615 R$**	9 417 R$	−1 198 R$

- **Le modèle final prédit mieux** sur toutes les mesures, en 2017 comme en 2018, et ne sous-estime plus le niveau du risque.

- **Son avantage vient surtout de la géographie.** Avec un plafond par région, il gagne 1 189 R$ en refusant davantage à Rio de Janeiro et en Espírito Santo. Le plafond par État lui retire cet avantage : à l'intérieur d'un même État, il ne classe pas mieux que le modèle initial.
- **Les deux modèles prennent la même décision pour 89 % des commandes.**
- **Le modèle final reste celui choisi sur la validation 2017**, où il devance la forêt initiale même avec le plafond par État (4 188 contre 4 145 R$ de bénéfice moyen). Revenir à la forêt parce qu'elle fait mieux en 2018 reviendrait à choisir le modèle sur le test.

1 Problématique

AssurColis, une insurtech fictive, veut proposer aux acheteurs de la plateforme Olist une **garantie de livraison** au moment du paiement :

- prix unique : **4 R$** par commande ;
- en cas de retard (le *sinistre*), le client est remboursé de ses frais de port et reçoit un bon d'achat de **15 R$**.

La question posée au modèle est donc : *au moment du paiement, quelle est la probabilité que ce colis arrive après la date promise ?* La réponse sert à décider, commande par commande, si l'on propose la garantie.

1.1 La règle de décision

Pour chaque commande, on calcule le coût attendu chargé de la marge de l'assureur :

$$\text{coût attendu} = \hat{p}_{\text{retard}} \times (\text{frais de port} + 15) \times 1{,}3$$

La garantie est proposée si ce coût est inférieur ou égal au prix, 4 R$. Le refus dépend donc à la fois du risque prédit et du montant de l'indemnité : un colis cher à expédier peut être refusé même avec un risque moyen.

1.2 La contrainte d'équité

L'État du client n'est pas une variable du modèle, mais la distance et le délai promis sont fortement liés à la géographie. Pour éviter d'exclure de fait les régions éloignées, la règle impose **au plus 20 % de refus dans chacune des cinq régions du Brésil**. Quand une région dépasse ce plafond, on re-propose la garantie aux commandes refusées les moins risquées.

1.3 Hypothèse de souscription

On suppose que 20 % des clients à qui la garantie est proposée l'achètent. Cette hypothèse n'est pas observable ; elle multiplie tous les bénéfices sans changer le classement des stratégies.

2 Données

2.1 Source et périmètre

Les données proviennent du jeu public Olist (commandes, clients, vendeurs, produits, paiements, avis, géolocalisation), chargé dans une base SQLite. Le périmètre retenu va de janvier 2017 à août 2018, soit 97 300 commandes livrées dont 7,8 % en retard. Avant 2017, les commandes sont trop rares ; après août 2018, l'issue des commandes n'est pas encore connue.

Le retard a un vrai coût pour la plateforme : **63 % des commandes en retard reçoivent un avis de 1 ou 2 étoiles**, contre 9 % des commandes livrées à temps.

2.2 Découpage temporel

Rôle	Période	Commandes	Taux de retard
Choix du modèle : apprentissage	janv.–sept. 2017	—	—
Choix du modèle : validation	oct.–déc. 2017	—	—
Entraînement final	janv.–déc. 2017	43 956	6,8 %
Test (regardé une seule fois)	janv.–août 2018	53 344	8,7 %

Ce découpage simule une mise en production : le modèle n'a jamais vu de commande postérieure à celles qu'il doit juger.

2.3 Variables utilisées

Seules les informations connues *au moment du paiement* sont utilisées.

Variable	Contenu
`delai_promis_jours`	délai annoncé au client entre l'achat et la livraison
`distance_km`	distance entre le vendeur et le client
`meme_etat`	1 si le vendeur et le client sont dans le même État
`frais_port`	frais de port payés (R$)
`prix_total`	montant des articles (R$)
`poids_total_g`, `volume_total_cm3`	poids et volume du colis
`nb_articles`, `nb_vendeurs`	complexité de la commande
`nb_mensualites`	nombre de paiements échelonnés
`type_paiement`	carte, boleto, voucher, débit (catégorielle)

Variables écartées volontairement. L'État et les coordonnées GPS (équité), le mois et le jour d'achat (ils apprennent des pics de 2017 qui ne se répètent pas), l'historique de retard du vendeur et la catégorie de produit (aucun gain en validation).

3 Le modèle

3.1 Pipeline

Le modèle est un `Pipeline` scikit-learn en deux blocs :

1. **Préparation** (`ColumnTransformer`) : pour les dix variables numériques, imputation des valeurs manquantes par la médiane puis standardisation ; pour `type_paiement`, encodage one-hot. Ces transformations sont apprises sur l'entraînement seulement.
2. **Estimateur** : `RandomForestClassifier` avec 300 arbres, `min_samples_leaf=100`, `max_features="sqrt"`, `random_state=42`.

Le paramètre `min_samples_leaf=100` impose qu'une feuille regroupe au moins 100 commandes, ce qui lisse les probabilités et limite le surapprentissage sur une cible rare (7 %).

3.2 Choix du modèle

Quatre candidats ont été comparés sur la validation d'octobre à décembre 2017, avec comme critère le **bénéfice de l'assureur** et non la ROC-AUC.

Candidat	ROC-AUC validation	Bénéfice validation
Régression logistique	**0,602**	2 710 R$
Forêt, feuilles ≥ 50	0,569	2 636 R$
Forêt, feuilles ≥ 100 (retenue)	0,574	**2 742 R$**
Forêt, feuilles ≥ 200	0,575	2 608 R$
Proposer à tous (sans modèle)	0,500	797 R$

Point d'attention

La forêt retenue devance la régression logistique de seulement **32 R$** (1,2 %) en bénéfice, alors que la logistique classe mieux (ROC-AUC 0,602 contre 0,574). L'écart est trop faible pour être significatif sur une validation de trois mois : le choix de la forêt est fragile.

3.3 Stabilité dans le temps

Une validation croisée temporelle en quatre plis sur 2017 (on apprend toujours sur le passé et on juge sur la suite) donne une ROC-AUC de **0,602** ± **0,016** (plis : 0,579 ; 0,611 ; 0,623 ; 0,597). Le modèle est stable, mais à un niveau modeste.

4 Résultats sur le test 2018

4.1 Comparaison des stratégies

Stratégie	Proposée à	Bénéfice	S/P
Proposer à tous (situation actuelle)	100,0 %	5 191 R$	0,88
Règle : refuser au-delà de 2 000 km	97,1 %	6 721 R$	0,84
Contrôle : refus au hasard (même nombre)	81,8 %	4 578 R$	0,87
Modèle, sans plafond par région	73,3 %	13 329 R$	0,57
Modèle, plafond de 20 % par région	**81,8 %**	**11 049 R$**	**0,68**

- Le modèle bat le contrôle au hasard de 6 471 R$: son gain vient bien du tri des commandes et pas seulement du fait de refuser.
- La contrainte d'équité coûte **2 279 R$** (13 329 contre 11 049). C'est le prix d'un traitement comparable entre régions.

4.2 Capacité de tri

- **ROC-AUC 0,641** : en tirant au hasard une commande en retard et une commande à l'heure, le modèle donne le risque le plus élevé à la première dans 64 % des cas.
- **PR-AUC 0,144**, contre 0,087 pour un tri au hasard : gain réel, mais faible.
- Le décile le plus risqué a un taux de retard de 17,6 %, cinq fois celui du décile le moins risqué (3,5 %). Le modèle sépare bien les extrêmes.

4.3 Calibration

La décision utilise directement la probabilité prédite : si elle est trop basse, le coût attendu est sous-estimé et l'assureur propose la garantie à des commandes non rentables.

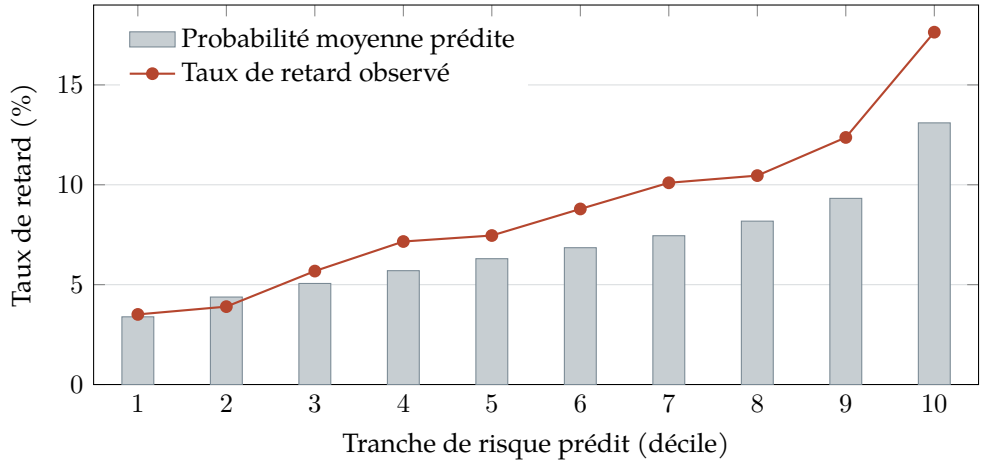


Fig. 1 : Calibration sur le test 2018 (53 344 commandes, environ 5 335 par décile).

Décile	Prédit	Observé	Écart
1	3,4 %	3,5 %	+0,1 pt
2	4,4 %	3,9 %	−0,5 pt
3	5,1 %	5,7 %	+0,6 pt
4	5,7 %	7,2 %	+1,5 pt
5	6,3 %	7,5 %	+1,2 pt
6	6,9 %	8,8 %	+1,9 pt
7	7,5 %	10,1 %	+2,7 pt
8	8,2 %	10,5 %	+2,3 pt
9	9,3 %	12,4 %	+3,1 pt
10	13,1 %	17,6 %	**+4,5 pt**

L'ordre des déciles est respecté, mais **le modèle sous-estime le risque à partir du quatrième décile**, et d'autant plus que le risque est élevé. En moyenne, il prédit 7,0 % de retards quand 8,7 % se produisent. Le score de Brier (0,0783) n'améliore que de 1,5 % la référence sans modèle (0,0795).

4.4 Importance des variables

Importance par permutation, mesurée sur le test avec la ROC-AUC (baisse de la ROC-AUC quand on mélange la variable). Une variable importante est utilisée par le modèle ; ce n'est pas une cause du retard.

Variable	Importance	Écart-type
`distance_km`	0,0446	0,0016
`delai_promis_jours`	0,0440	0,0010
`meme_etat`	0,0340	0,0009
`frais_port`	0,0144	0,0009
`nb_articles`	0,0058	0,0004
`nb_vendeurs`	0,0026	0,0005
`type_paiement`	0,0024	0,0005
`prix_total`	0,0023	0,0004
`poids_total_g`	0,0005	0,0011
`nb_mensualites`	−0,0009	0,0002
`volume_total_cm3`	−0,0014	0,0010

Trois variables géographiques (distance, délai promis, même État) portent l'essentiel du signal. `poids_total_g` a une importance inférieure à son écart-type, et deux variables ont une importance **négative** : les mélanger améliore la ROC-AUC sur 2018. Elles apportent du bruit appris sur 2017.

4.5 Équité par région

Région	Commandes	Part refusée	Taux de retard	Seuil de coût
Sudeste	37 157	17,5 %	7,9 %	4,00 R$
Sul	7 374	20,0 %	7,2 %	4,53 R$
Centro-Oeste	3 147	20,0 %	8,9 %	5,40 R$
Norte	883	19,9 %	14,0 %	9,06 R$
Nordeste	4 783	20,0 %	16,5 %	10,29 R$

Le plafond est respecté partout. Il est atteint dans quatre régions sur cinq : seul le Sudeste reste sous la limite avec la règle de prix normale (seuil de 4 R$). Dans le Nordeste et le Norte, le seuil est relevé à environ 9 à 10 R$: on y propose une garantie à 4 R$ à des commandes dont le coût attendu peut atteindre plus du double. C'est là que se concentre le coût de l'équité.

4.6 Profils de commandes

Une segmentation K-means (5 segments, apprise sur 2017) aide à lire les décisions.

Segment	Part	Retard 2017	Retard 2018	Refusées 2018
Le voisin (même État)	30,1 %	4,6 %	5,7 %	2,5 %
Le petit colis entre États	36,8 %	7,6 %	11,7 %	10,4 %
Le grand voyageur (très longue distance)	14,6 %	6,9 %	7,0 %	11,9 %
Le colis lourd	16,3 %	9,2 %	10,8 %	67,7 %
Le gros panier (plusieurs articles)	2,3 %	4,7 %	5,8 %	70,9 %

Les colis lourds et les gros paniers sont refusés à près de 70 % alors que leur taux de retard n'est pas le plus élevé : ils sont refusés surtout parce que leurs frais de port, donc l'indemnité, sont élevés. À l'inverse, le « petit colis entre États » voit son taux de retard passer de 7,6 % à 11,7 % en 2018 mais n'est refusé qu'à 10 %.

5 Dérive temporelle

Le taux de retard n'est pas stable :

- en 2017, il oscille entre 4 et 6 %, sauf en novembre (13,3 %), qui est aussi le mois le plus chargé de l'année (7 360 commandes, contre environ 4 200 les mois précédents) ;
- en 2018, **février (14,9 %) et mars (20,5 %)** sont des mois de crise, puis le taux redescend jusqu'à 1,9 % en juin.

Le modèle, appris sur une année plutôt calme, ne peut pas anticiper ces épisodes : les variables connues au paiement ne disent rien de l'état du réseau de transport à venir. Cette dérive explique en grande partie la sous-estimation observée en calibration (7,0 % prédit contre 8,7 % observé).

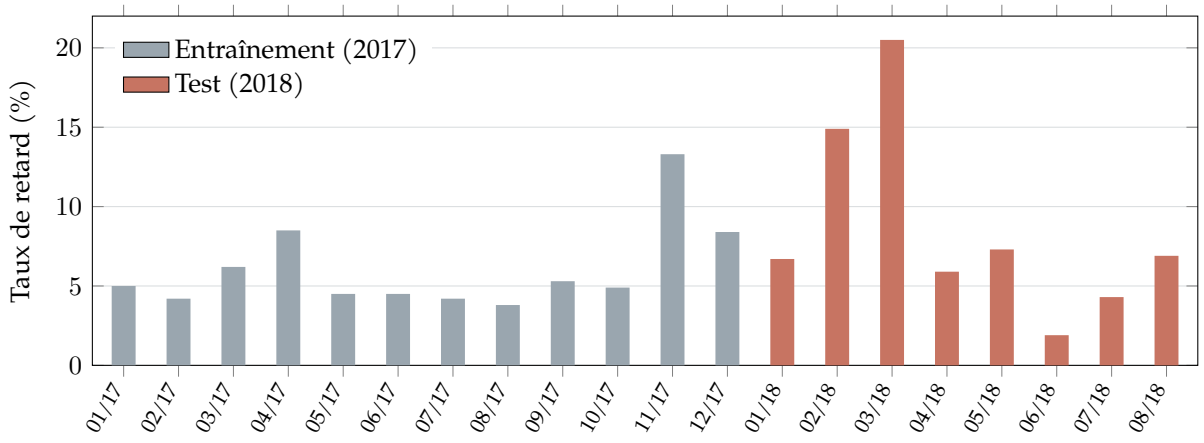


Fig. 2 : Taux de retard mensuel, janvier 2017 à août 2018.

6 Bilan et pistes d'amélioration

6.1 Forces

- Méthode d'évaluation rigoureuse : split temporel, test unique, contrôle au hasard.
- Critère de choix aligné sur le métier (bénéfice de l'assureur).
- Gain économique réel : 11 049 R$, soit $\times 2{,}1$ par rapport à la situation actuelle.
- Contrainte d'équité respectée et chiffrée (coût de 2 279 R$).
- Code clair : tous les paramètres sont centralisés dans `backend/config.py`.

6.2 Faiblesses

- Capacité de tri modeste (ROC-AUC 0,641).
- Probabilités sous-estimées dans les déciles risqués, alors que la décision s'appuie directement sur elles.
- Deux variables à importance négative, une troisième sans effet mesurable.
- Choix forêt contre logistique tranché sur un écart de 32 R$ seulement.
- Sensibilité forte à la dérive temporelle, sans mécanisme de suivi ni de réentraînement.

6.3 Pistes à tester

Chaque piste sera évaluée de la même façon que le modèle actuel : choix sur la validation 2017, puis comparaison sur le test 2018 avec le bénéfice de l'assureur comme critère principal.

Priorité	Piste	Effet attendu
1	Retirer `volume_total_cm3` et `nb_mensualites`	moins de bruit
1	Calibrer les probabilités (`CalibratedClassifierCV`, isotonique ou sigmoïde)	coût attendu juste
2	Tester `HistGradientBoostingClassifier`	meilleur tri
2	Ajouter des variables construites (distance / délai promis, frais par kg)	meilleur tri
3	Revoir le choix forêt / logistique avec plusieurs fenêtres de validation	choix plus robuste
3	Suivre le taux de retard mensuel et prévoir un réentraînement régulier	résistance à la dérive

Les deux pistes de priorité 1, ainsi que la comparaison forêt / logistique sur plusieurs fenêtres, ont été testées : la section suivante en rend compte.

7 Premiers essais d'amélioration

7.1 Protocole

Les essais sont jugés **uniquement sur 2017** ; le test 2018 n'a pas été relu. Pour ne pas dépendre d'une seule période, chaque variante est évaluée sur deux fenêtres de validation, en apprenant toujours sur le passé :

Fenêtre	Apprentissage → validation	App.	Val.	Taux de retard
F1	janv.–juin 2017 → juil.–sept. 2017	14 165	12 350	4,4 %
F2	janv.–sept. 2017 → oct.–déc. 2017	26 515	17 441	9,5 %

La calibration utilise `CalibratedClassifierCV` avec des plis temporels (`TimeSeriesSplit`, 3 plis) : chaque calibrateur est appris sur des commandes postérieures à celles qui ont servi au modèle. Les « 9 variables » sont les 11 variables actuelles sans `volume_total_cm3` ni `nb_mensualites`.

7.2 Résultats

	ROC-AUC		Bénéfice	
Variante	F1	F2	F1	F2
A. Forêt, 11 variables (actuel)	0,605	0,575	5 711 R$	2 750 R$
B. Forêt, 9 variables	0,608	0,575	5 710 R$	2 729 R$
C. Forêt, 9 var. + isotonique	0,587	0,571	5 758 R$	2 512 R$
D. Forêt, 9 var. + sigmoïde	0,582	0,564	5 779 R$	2 448 R$
E. Logistique, 11 variables	**0,630**	**0,602**	5 756 R$	2 710 R$
F. Logistique, 9 variables	**0,639**	**0,601**	5 714 R$	2 706 R$
G. Logistique, 9 var. + isotonique	0,640	0,595	5 763 R$	2 529 R$
Proposer à tous (sans modèle)	0,500	0,500	5 510 R$	797 R$

7.3 Lecture

Retirer les deux variables ne change rien. Sur 2017, la ROC-AUC et le bénéfice sont identiques à quelques unités près. Leur importance négative avait été mesurée sur 2018 ; s'appuyer sur ce

constat pour les retirer reviendrait à régler le modèle sur le test. On peut les retirer par souci de simplicité, pas pour un gain de performance.

La calibration dégrade le résultat. Elle fait perdre jusqu'à 300 R$ sur F2 et abaisse la ROC-AUC. Le tableau suivant montre pourquoi :

Fenêtre	Proba. moyenne prédite	Taux observé	Lecture
F1 (juil.–sept.)	5,6 %	4,4 %	le modèle surestime
F2 (oct.–déc.)	5,0 %	9,5 %	le modèle sous-estime de moitié

Conclusion principale

Les probabilités ne sont pas mal formées : c'est le **niveau général du risque qui change d'un trimestre à l'autre**, alors que le modèle prédit toujours à peu près le même niveau. Un calibrateur appris sur le passé ne peut pas deviner le niveau à venir. Le défaut de calibration observé en 2018 est un symptôme de la dérive temporelle, pas un problème de réglage.

La régression logistique trie mieux que la forêt. Elle gagne 0,025 à 0,03 de ROC-AUC sur les deux fenêtres, pour un bénéfice équivalent. Le choix initial de la forêt, tranché sur 32 R$ d'écart, ne tient pas.

Le bénéfice départage mal les variantes. Les écarts entre variantes (environ 50 R$) relèvent du bruit : avec le plafond de 20 % de refus par région, la garantie est proposée à environ 90 % des commandes de validation, ce qui laisse peu de place pour distinguer les modèles. La ROC-AUC et la PR-AUC sont ici plus informatives.

7.4 Pistes révisées

Priorité	Piste	Statut
—	Retirer `volume_total_cm3` et `nb_mensualites`	neutre, simplification
—	Calibrer les probabilités	écarté
1	Ajouter le taux de retard récent du réseau (30 derniers jours, commandes déjà livrées à la date d'achat)	écarté (section 8)
1	Ajouter la marge du délai promis (délai promis moins délai habituel sur le même trajet, calculé sur le passé)	retenu (section 8)
2	Comparer logistique, forêt et `HistGradientBoostingClassifier` avec ces variables	logistique retenue
3	Simuler un réentraînement mensuel sur 2018	à tester

La variable de taux de retard récent vise directement la cause identifiée : elle donne au modèle le niveau de risque du moment, qu'il ne voit pas aujourd'hui. Elle exige une précaution contre la fuite d'information : seules les commandes déjà livrées à la date d'achat peuvent entrer dans son calcul.

8 Nouveau modèle : les variables « trajet »

8.1 Les variables

Pour chaque commande, on regarde les livraisons passées sur le même trajet (État du vendeur → État du client), telles qu'elles étaient connues **le 1er jour du mois d'achat** :

- `delai_habituel_trajet` : délai réel médian entre l'achat et la livraison, sur les commandes déjà livrées (médiane globale si le trajet compte moins de 30 livraisons) ;
- `marge_delai_jours` : délai promis au client moins ce délai habituel. Une marge faible signifie qu'Olist promet moins que ce que le trajet prend d'habitude ;
- `taux_retard_trajet` : taux de retard passé du trajet, sur les commandes dont la date promise est passée, rapproché du taux global pour les trajets peu fréquentés.

Une quatrième variable a été testée puis écartée : le **taux de retard des 30 derniers jours**. L'issue d'une commande n'est connue qu'à sa date promise, environ trois à quatre semaines après l'achat : ce signal décrit donc la situation d'il y a un mois. Il indiquait 4,8 % en novembre 2017 (13,3 % réels) et 20 % en avril 2018 (5,9 % réels), une fois la crise passée.

Les deux variables neutres (`volume_total_cm3`, `nb_mensualites`) ont été retirées : le modèle compte désormais **12 variables**. L'absence de fuite est vérifiée par des tests automatiques (`tests/test_trajets.py`) et par un recalcul à la main sur plusieurs dates.

8.2 Choix du modèle sur la validation 2017

Le critère de choix a été fixé avant de regarder le test : la **ROC-AUC moyenne sur les deux fenêtres** F1 et F2. Le bénéfice est calculé mais ne départage pas les candidats (section 7).

	ROC-AUC		Bénéfice	
Candidat (12 variables)	F1	F2	F1	F2
Régression logistique (retenue)	**0,647**	**0,642**	5 819 R$	2 658 R$
Forêt, feuilles ≥ 100	0,632	0,620	5 615 R$	2 795 R$
Gradient boosting	0,599	0,628	5 614 R$	2 959 R$
Rappel : forêt actuelle (11 variables)	0,605	0,575	5 711 R$	2 750 R$

La validation croisée temporelle sur 2017 donne **0,645 ± 0,027**, contre 0,602 ± 0,016 pour le modèle actuel.

8.3 Résultats sur le test 2018

Le test a été regardé une fois, après le choix du modèle.

Indicateur (test 2018)	Modèle actuel	Nouveau modèle	Écart
ROC-AUC	0,641	**0,673**	+0,032
PR-AUC (hasard : 0,087)	0,144	**0,150**	+0,006
Score de Brier	0,0783	**0,0776**	−0,0007
Probabilité moyenne prédite (réel : 8,7 %)	7,0 %	9,0 %	
Bénéfice, plafond de 20 % par région	11 049 R$	**12 238 R$**	+1 189 R$
Ratio sinistres / primes	0,68	**0,64**	−0,04
Part des commandes à qui on propose	81,8 %	80,0 %	
Bénéfice sans plafond	13 329 R$	14 428 R$	+1 099 R$
Coût de l'équité	2 279 R$	2 189 R$	

Pour information, les deux autres candidats ont aussi été évalués sur le test, sans que ce résultat serve à changer de choix : forêt 0,648 de ROC-AUC et 10 911 R$; gradient boosting 0,629 et 10 576 R$. Le choix fait sur la validation est confirmé.

Calibration. Le modèle ne sous-estime plus le niveau du risque (9,0 % prédit pour 8,7 % observé). Il surestime en revanche la tranche la plus risquée (22,0 % prédit contre 17,6 % observé), ce qui rend l'assureur un peu trop prudent sur ces commandes.

Importance des variables. Les deux variables trajet les plus utiles arrivent en tête : `marge_delai_jours` (0,034) et `taux_retard_trajet` (0,032), devant le délai promis (0,023), le fait d'être dans le même État (0,022) et la distance (0,018).

8.4 Équité : un arbitrage à trancher

Le plafond est respecté : chaque région a 20 % de refus. Il est désormais atteint dans les cinq régions, Sudeste compris. Sans plafond, le nouveau modèle refuserait 93,5 % des commandes du Nordeste et 87,9 % de celles du Norte : il repère encore mieux la géographie que le modèle actuel.

Surtout, à l'intérieur des régions, les refus se concentrent sur certains États :

Région	État	Commandes	Retard	Refus actuel	Refus nouveau
Sudeste	Espírito Santo (ES)	1 054	14,3 %	30,9 %	**65,6 %**
Sudeste	Rio de Janeiro (RJ)	6 504	15,9 %	25,9 %	**58,5 %**
Sudeste	São Paulo (SP)	23 485	5,6 %	12,5 %	7,6 %
Nordeste	Alagoas (AL)	202	23,8 %	20,3 %	**52,0 %**
Nordeste	Maranhão (MA)	354	21,8 %	34,7 %	48,6 %
Nordeste	Bahia (BA)	1 762	15,8 %	9,1 %	9,3 %
Sul	Santa Catarina (SC)	1 892	9,2 %	22,3 %	35,8 %
Sul	Paraná (PR)	2 724	5,2 %	18,3 %	9,8 %

Parmi les États d'au moins 200 commandes, l'écart entre le taux de refus le plus haut et le plus bas passe de 30 à **58 points**. Les refus suivent mieux le risque réel (Rio de Janeiro et Espírito Santo ont des taux de retard deux à trois fois supérieurs à São Paulo), ce qui explique le gain de bénéfice. Mais l'État du client avait été exclu du modèle pour l'équité, et les variables trajet le réintroduisent indirectement.

Décision à prendre par l'équipe

- **Garder le nouveau modèle tel quel** et documenter l'écart entre États : +1 189 R$, plafond par région respecté.
- **Plafonner les refus par État** plutôt que par région : même règle, maille plus fine ; le coût est à mesurer sur la validation.
- **Calculer les variables trajet par région** (région du vendeur → région du client) plutôt que par État : moins précis, moins discriminant entre États.

Les deux dernières options doivent être évaluées sur la validation 2017 avant toute nouvelle lecture du test.

9 Choix d'équité : un plafond par État

9.1 Options évaluées sur la validation 2017

Deux options ont été comparées au nouveau modèle sur les fenêtres F1 et F2, sans relire le test. L'écart de refus entre États est mesuré sur les États d'au moins 100 commandes.

	ROC-AUC		Bénéfice	
Variante	F1	F2	F1	F2
Nouveau modèle, plafond par région	0,647	0,642	5 819 R$	2 658 R$
Option 2 : plafond par État	0,647	0,642	5 743 R$	2 633 R$
Option 3 : trajets entre régions	0,641	0,573	5 732 R$	2 315 R$
Options 2 et 3	0,641	0,573	5 746 R$	2 179 R$
Forêt actuelle, plafond par État	0,607	0,574	5 703 R$	2 586 R$

- **L'option 3 est écartée.** Calculées entre régions, les variables trajet perdent leur pouvoir de tri : sur F2, la ROC-AUC tombe à 0,573, sous la logistique sans variable trajet (0,601).
- **L'option 2 ne change pas le modèle**, seulement la règle de décision. Sur 2017, elle coûte de 25 à 76 R$ et ramène chaque État à 20 % de refus au plus (contre 31 à 32 % au maximum avec le plafond par région). Avec cette règle, le nouveau modèle reste devant la forêt actuelle (4 188 R$ de bénéfice moyen contre 4 145 R$).

9.2 Résultat sur le test 2018

Règle (nouveau modèle)	Proposée à	Bénéfice	S/P	Refus par État
Sans plafond	60,8 %	14 428 R$	0,44	—
Plafond de 20 % par région	80,0 %	12 238 R$	0,64	7,6 à 65,6 %
Plafond de 20 % par État (retenu)	**83,9 %**	**9 417 R$**	**0,74**	**11,2 à 20,0 %**
Proposer à tous	100,0 %	5 191 R$	0,88	—

Pourquoi l'écart avec la validation

Sur 2017, passer de la région à l'État coûtait moins de 80 R$. Sur 2018, il coûte **2 821 R$**. En 2018, les retards ont fortement augmenté à Rio de Janeiro (15,9 %) et en Espírito Santo (14,3 %), contre 5,6 % à São Paulo : le gain du nouveau modèle venait surtout de refus concentrés sur ces États, ce que le plafond par État interdit. Avec la même règle, l'ancienne forêt aurait obtenu 10 615 R$ sur 2018. Revenir à la forêt pour cette raison reviendrait à choisir le modèle sur le test : le choix reste celui de la validation.

9.3 Bilan

- La règle est cohérente avec le principe d'équité du projet : l'État du client est exclu des variables, et aucun État ne peut être refusé à plus de 20 %.
- Le coût total de l'équité est de **5 011 R$** sur 8 mois (14 428 contre 9 417 R$). La garantie reste rentable : bénéfice multiplié par 1,8 et ratio sinistres / primes de 0,74.
- Le seuil de coût est fixé par État : 4,00 R$ à São Paulo, de 4,7 à 9 R$ dans le reste du Sudeste, le Sul et le Centro-Oeste, de 7,5 à 16 R$ dans le Norte et de 12,7 à 28,0 R$ dans le Nordeste.
- À suivre en production : la part de refus par État chaque mois, en particulier dans les petits États où elle varie beaucoup.